

Πανεπιστήμιο Πειραιώς

Τεκμηρίωση Εργασίας Μαθήματος «Επεξεργασία Σημάτων Φωνής και Ήχου»

Φοιτητής: Μύαρης Στυλιανός Π22114

1. Εισαγωγή

Η ανίχνευση δραστηριότητας ομιλίας (Voice Activity Detection – VAD) αποτελεί βασικό πρόβλημα στην επεξεργασία σήματος ομιλίας. Στόχος της είναι ο διαχωρισμός ενός ηχητικού σήματος σε τμήματα που περιέχουν ομιλία και σε τμήματα που περιέχουν μόνο θόρυβο ή ήχους υποβάθρου. Η διαδικασία αυτή χρησιμοποιείται ευρέως σε εφαρμογές αναγνώρισης ομιλίας, τηλεπικοινωνιών, τηλεδιασκέψεων και συστημάτων αυτόματης μεταγραφής.

Σκοπός της παρούσας εργασίας είναι η ανάπτυξη ενός συστήματος που πραγματοποιεί κατάτμηση μιας ηχογράφησης σε τμήματα foreground (ομιλία) και background (υπόβαθρο). Η προσέγγιση βασίζεται σε ταξινόμηση ανά frame χρησιμοποιώντας δύο διαφορετικούς ταξινομητές, k-Nearest Neighbors (k-NN) και Multi-Layer Perceptron (MLP), και στη συνέχεια εφαρμόζεται μετα-επεξεργασία των αποφάσεων του ταξινομητή ώστε να εξαχθούν συνεχόμενα χρονικά τμήματα ομιλίας και υποβάθρου. Τα τελικά αποτελέσματα αποθηκεύονται σε αρχείο CSV που περιέχει τα χρονικά όρια κάθε τμήματος.

2. Δεδομένα

Για την εκπαίδευση των ταξινομητών χρησιμοποιήθηκαν τα δεδομένα που δόθηκαν στην εκφώνηση και προέρχονται από τα σύνολα δεδομένων MUSAN και CHiME. Τα αρχεία εκπαίδευσης είναι οργανωμένα σε δύο κατηγορίες: speech και noise.

Για λόγους υπολογιστικού κόστους χρησιμοποιήθηκε υποσύνολο των διαθέσιμων δεδομένων, αποτελούμενο από 80 αρχεία ομιλίας και 80 αρχεία θορύβου. Από κάθε αρχείο εξήχθησαν χαρακτηριστικά σε επίπεδο frame και δημιουργήθηκε το σύνολο εκπαίδευσης των ταξινομητών.

Για την αξιολόγηση χρησιμοποιήθηκε το αρχείο S01_U04.CH4.wav, το οποίο προέρχεται από το σύνολο δεδομένων CHiME. Το αρχείο αναλύθηκε σε διαδοχικά frames και για κάθε frame πραγματοποιήθηκε ταξινόμηση σε speech ή background.

Ως ground truth χρησιμοποιήθηκε το αρχείο μεταγραφής S01.json. Από το αρχείο αυτό διατηρήθηκαν μόνο οι χρονικές σημάνσεις έναρξης και λήξης της ομιλίας. Οι χρονικές σημάνσεις μετατράπηκαν σε ετικέτες ανά frame, όπου η τιμή 1 αντιστοιχεί σε ομιλία και η τιμή 0 σε υπόβαθρο.

3. Εξαγωγή Χαρακτηριστικών

Η επεξεργασία του σήματος πραγματοποιήθηκε σε μικρά χρονικά τμήματα (frames). Χρησιμοποιήθηκε μήκος frame ίσο με 25 ms και βήμα μετατόπισης 10 ms, με αποτέλεσμα διαδοχικά επικαλυπτόμενα frames.

Από κάθε frame εξήχθησαν συνολικά 15 χαρακτηριστικά:

- 13 συντελεστές MFCC (Mel Frequency Cepstral Coefficients)
- RMS Energy
- Zero Crossing Rate (ZCR)

Οι MFCC αποτελούν το πιο διαδεδομένο χαρακτηριστικό στην επεξεργασία ομιλίας, καθώς περιγράφουν το φασματικό περιεχόμενο του σήματος με τρόπο που προσεγγίζει την ανθρώπινη ακοή. Η ενέργεια βοηθά στη διάκριση μεταξύ ενεργής ομιλίας και σιωπής, ενώ το Zero Crossing Rate παρέχει πληροφορία σχετικά με τη συχνότητα εναλλαγής του σήματος γύρω από το μηδέν.

Μετά την εξαγωγή τους, όλα τα χαρακτηριστικά κανονικοποιήθηκαν με χρήση του StandardScaler, ώστε να έχουν μηδενικό μέσο όρο και μοναδιαία τυπική απόκλιση. Η κανονικοποίηση είναι απαραίτητη τόσο για τον k-NN όσο και για το MLP ώστε όλα τα χαρακτηριστικά να συνεισφέρουν ισότιμα στη διαδικασία ταξινόμησης.

4. Ταξινομητές

4.1 k-NN

Ο ταξινομητής k-Nearest Neighbors ταξινομεί κάθε νέο δείγμα με βάση τις ετικέτες των k πλησιέστερων γειτόνων του στον χώρο χαρακτηριστικών. Στην παρούσα εργασία χρησιμοποιήθηκε $k = 5$ και ως μέτρο απόστασης η Ευκλείδεια απόσταση.

Για την επιτάχυνση της αναζήτησης γειτόνων χρησιμοποιήθηκε η δομή BallTree. Επιπλέον, επειδή ο χρόνος πρόβλεψης του k-NN αυξάνεται σημαντικά με το μέγεθος του συνόλου εκπαίδευσης, χρησιμοποιήθηκε τυχαίο υποσύνολο 50.000 frames ανά κλάση. Η επιλογή αυτή μείωσε σημαντικά τον χρόνο εκτέλεσης.

4.2 MLP

Ο δεύτερος ταξινομητής ήταν ένα νευρωνικό δίκτυο τύπου Multi-Layer Perceptron (MLP). Η αρχιτεκτονική του αποτελείται από:

- 15 νευρώνες εισόδου (ένας για κάθε χαρακτηριστικό)
- Πρώτο κρυφό επίπεδο με 128 νευρώνες
- Δεύτερο κρυφό επίπεδο με 64 νευρώνες
- Επίπεδο εξόδου δύο κλάσεων

Ως activation function χρησιμοποιήθηκε η ReLU, ενώ η εκπαίδευση πραγματοποιήθηκε με τον αλγόριθμο Adam. Εφαρμόστηκε επίσης early stopping ώστε η εκπαίδευση να σταματά αυτόματα όταν δεν παρατηρείται περαιτέρω βελτίωση στο validation set, μειώνοντας τον κίνδυνο υπερπροσαρμογής.

5. Ισορροπία Κλάσεων

Τα δεδομένα εκπαίδευσης παρουσίαζαν ανισορροπία μεταξύ των κλάσεων speech και noise. Σε τέτοιες περιπτώσεις ένας ταξινομητής μπορεί να ευνοεί την πολυπληθέστερη κλάση και να εμφανίζει παραπλανητικά υψηλή ακρίβεια.

Για την αντιμετώπιση του προβλήματος εφαρμόστηκε εξισορρόπηση μέσω τυχαίας υποδειγματοληψίας (random subsampling). Ο αριθμός των frames της κλάσης πλεοψηφίας μειώθηκε ώστε οι δύο κλάσεις να περιέχουν ίσο πλήθος δειγμάτων.

6. Περιγραφή Κώδικα

Η λύση υλοποιήθηκε σε Python και οργανώθηκε σε τρία βασικά αρχεία: `feature_extraction.py`, `train.py` και `evaluate.py`.

`feature_extraction.py`

Το αρχείο αυτό περιλαμβάνει όλες τις συναρτήσεις που σχετίζονται με την επεξεργασία του ηχητικού σήματος και την εξαγωγή χαρακτηριστικών. Αρχικά φορτώνει αρχεία μορφής WAV μέσω της βιβλιοθήκης Librosa και τα μετατρέπει σε μονοφωνικό σήμα (mono) με συχνότητα δειγματοληψίας 16 kHz, ώστε όλα τα δεδομένα να έχουν κοινή μορφή.

Στη συνέχεια το σήμα χωρίζεται σε frames διάρκειας 25 ms με βήμα 10 ms και από κάθε frame εξάγονται τα 15 χαρακτηριστικά που χρησιμοποιούνται στην εργασία: 13 συντελεστές MFCC, η RMS Energy και το Zero Crossing Rate. Το αρχείο περιλαμβάνει επίσης βοηθητικές συναρτήσεις για τη συλλογή χαρακτηριστικών από πολλαπλά αρχεία εκπαίδευσης και χρησιμοποιείται ως κοινή βιβλιοθήκη από τα υπόλοιπα αρχεία του έργου.

`train.py`

Το αρχείο `train.py` υλοποιεί τη διαδικασία εκπαίδευσης των ταξινομητών. Αρχικά εντοπίζει τα αρχεία ομιλίας και θορύβου στους φακέλους εκπαίδευσης και καλεί τις συναρτήσεις του `feature_extraction.py` για την εξαγωγή χαρακτηριστικών.

Στη συνέχεια πραγματοποιείται κανονικοποίηση των χαρακτηριστικών με χρήση του `StandardScaler` και εξισορρόπηση των κλάσεων μέσω τυχαίας υποδειγματοληψίας. Τα δεδομένα χωρίζονται σε σύνολο εκπαίδευσης και σύνολο επικύρωσης (validation set), πάνω στο οποίο αξιολογούνται οι ταξινομητές.

Το πρόγραμμα εκπαιδεύει έναν ταξινομητή k-NN και ένα νευρωνικό δίκτυο MLP, υπολογίζει τις μετρικές απόδοσης στο validation set και αποθηκεύει τα εκπαιδευμένα μοντέλα σε αρχεία (`knn.pkl`, `mlp.pkl`) για μεταγενέστερη χρήση.

`evaluate.py`

Το αρχείο `evaluate.py` χρησιμοποιείται για την αξιολόγηση των εκπαιδευμένων μοντέλων στο αρχείο δοκιμής. Αρχικά φορτώνει τα αποθηκευμένα μοντέλα και τον `StandardScaler` και εξάγει χαρακτηριστικά από το test αρχείο χρησιμοποιώντας τις ίδιες ακριβώς παραμέτρους με την εκπαίδευση.

Στη συνέχεια παράγονται προβλέψεις ανά frame για τους δύο ταξινομητές. Επειδή το αρχείο δοκιμής έχει μεγάλη διάρκεια, οι προβλέψεις πραγματοποιούνται τμηματικά (batch processing) ώστε να μειωθούν οι απαιτήσεις μνήμης.

Μετά την ταξινόμηση εφαρμόζεται median filter για εξομάλυνση των αποφάσεων. Οι τελικές προβλέψεις συγκρίνονται με τις ετικέτες που προκύπτουν από το αρχείο μεταγραφής JSON και υπολογίζονται οι μετρικές αξιολόγησης (Accuracy, Precision, Recall και F1-score). Τέλος, οι διαδοχικές προβλέψεις συγχωνεύονται σε χρονικά

τμήματα ομιλίας και υποβάθρου και αποθηκεύονται σε αρχεία CSV σύμφωνα με τις προδιαγραφές της εκφώνησης.

7. Μετα-επεξεργασία

Οι αποφάσεις των ταξινομητών παράγονται ανεξάρτητα για κάθε frame. Ως αποτέλεσμα, συχνά εμφανίζονται μεμονωμένα λανθασμένα frames μέσα σε μεγάλες περιοχές ομιλίας ή υποβάθρου, δημιουργώντας ασυνεχείς προβλέψεις.

Για την εξομάλυνση των αποτελεσμάτων εφαρμόστηκε φίλτρο διάμεσου (Median Filter) με παράθυρο 51 frames. Δεδομένου ότι το βήμα μεταξύ διαδοχικών frames είναι 10 ms, το παράθυρο αντιστοιχεί σε χρονική διάρκεια περίπου 510 ms.

Το φίλτρο αντικαθιστά κάθε πρόβλεψη με την πλειοψηφική τιμή μέσα στο τοπικό παράθυρο. Με τον τρόπο αυτό αποκλείονται λανθασμένα ψήγματα κλάσεων μειοψηφίας και επιτυγχάνεται η ομαλή εναλλαγή μεταξύ speech και noise.

8. Αποτελέσματα

Classifier	Accuracy	Precision (speech)	Recall (speech)	F1 (speech)
k-NN (πριν PP)	0.6673	0.7929	0.7811	0.7869
k-NN (μετά PP)	0.7149	0.7896	0.8693	0.8275
MLP (πριν PP)	0.6513	0.8079	0.7305	0.7672
MLP (μετά PP)	0.6945	0.8078	0.8026	0.8052

Τα αποτελέσματα δείχνουν ότι η μετα-επεξεργασία βελτίωσε σημαντικά τις επιδόσεις και των δύο ταξινομητών. Συγκεκριμένα, μετά την εφαρμογή του median filter αυξήθηκε το recall της κλάσης speech, γεγονός που σημαίνει ότι εντοπίστηκαν περισσότερα πραγματικά τμήματα ομιλίας.

Ο k-NN παρουσίασε την καλύτερη συνολική επίδοση μετά τη μετα-επεξεργασία, επιτυγχάνοντας F1-score ίσο με 0.8275 έναντι 0.8052 του MLP. Το αποτέλεσμα αυτό υποδηλώνει ότι τα επιλεγμένα χαρακτηριστικά δημιουργούν σχετικά καλά διαχωρίσιμες περιοχές στον χώρο χαρακτηριστικών, επιτρέποντας στον k-NN να λειτουργήσει ιδιαίτερα αποτελεσματικά.

Παρατηρείται επίσης ότι η κλάση background είναι σημαντικά δυσκολότερη στην αναγνώριση σε σχέση με την κλάση speech. Συγκεκριμένα, το F1-score της κλάσης background κυμάνθηκε μεταξύ 0.18 και 0.29 και στους δύο ταξινομητές, έναντι 0.77–0.83 για την κλάση speech. Αυτό πιθανότατα οφείλεται στο γεγονός ότι το αρχείο δοκιμής περιέχει μεγάλο ποσοστό ομιλίας (78.7%), ενώ τα πραγματικά τμήματα υποβάθρου παρουσιάζουν μεγαλύτερη ποικιλία και συχνά μοιάζουν φασματικά με ασθενή ή απομακρυσμένη ομιλία.

Τέλος, αν και το accuracy φαίνεται σχετικά υψηλό, δεν αποτελεί την καταλληλότερη μετρική λόγω της ανισορροπίας των κλάσεων στο σύνολο δοκιμής. Για τον λόγο αυτό μεγαλύτερη έμφαση δίνεται στο F1-score, το οποίο συνδυάζει πληροφορία τόσο από το precision όσο και από το recall.

9. Συμπεράσματα

Στην εργασία αναπτύχθηκε ένα σύστημα ανίχνευσης δραστηριότητας ομιλίας βασισμένο σε χαρακτηριστικά MFCC, Energy και Zero Crossing Rate. Υλοποιήθηκαν δύο ταξινομητές, k-NN και MLP, ενώ εφαρμόστηκε μετα-επεξεργασία μέσω median filtering για τη βελτίωση της χρονικής συνέχειας των προβλέψεων.

Τα αποτελέσματα έδειξαν ότι και οι δύο ταξινομητές μπορούν να εντοπίσουν αποτελεσματικά τα τμήματα ομιλίας, με τον k-NN να παρουσιάζει την καλύτερη τελική επίδοση. Η μετα-επεξεργασία βελτίωσε σημαντικά το recall και το F1-score, επιβεβαιώνοντας τη σημασία της στην κατάτμηση ηχητικών σημάτων.

Πιθανές μελλοντικές βελτιώσεις περιλαμβάνουν τη χρήση μεγαλύτερου συνόλου εκπαίδευσης, την εξαγωγή επιπλέον χαρακτηριστικών (όπως Δ-MFCC και ΔΔ-MFCC τα οποία είναι η πρώτη και δεύτερη παράγωγος του MFCC στον χρόνο και μετρούν αντίστοιχα το πόσο αλλάζουν τα δεδομένα από frame σε frame και την επιτάχυνση αυτής της αλλαγής) και τη διερεύνηση πιο σύνθετων τεχνικών μετα-επεξεργασίας των αποφάσεων ανά frame.